

PEL 202: Fundamentos de Inteligência Artificial
Lista de Exercícios

Matheus R. Teixeira

26 de maio de 2024

Questão 1: Suponha que você seja um cientista de dados que trabalha em um projeto para prever o preço de casas. Você tem um conjunto de dados com informações sobre casas, como tamanho, localização, número de quartos e banheiros, e preços de venda. Qual algoritmo de aprendizado de máquina você escolheria para treinar um modelo para prever o preço de novas casas? Justifique sua escolha. (Valor 2.0)

Para prever os preços das casas, eu selecionaria um modelo de Regressão Linear porque é um algoritmo de aprendizado supervisionado comumente usado para tarefas de regressão. A regressão linear é conveniente porque apresenta bom desempenho quando há uma relação linear entre as features de entrada (como tamanho, localização, número de quartos e banheiros) e os preços das casas.

Questão 2: Um modelo de aprendizado de máquina é treinado em um conjunto de dados com 1000 amostras, divididas em 70% para treinamento e 30% para teste. No conjunto de treinamento, o modelo obtém uma acurácia de 95%. No conjunto de teste, a acurácia é de 80%. Explique por que a acurácia no conjunto de teste é menor que no conjunto de treinamento e como essa diferença pode ser interpretada. (Valor 2.0)

A diferença de acurácia entre o conjunto de treinamento e o conjunto de teste provavelmente se deve ao overfitting. Overfitting ocorre quando o modelo aprende muito bem os dados de treinamento e consequentemente tem um desempenho muito bom no conjunto de treinamento, mas não consegue generalizar tão bem para dados novos (conjunto de teste).

Questão 3: Descreva os diferentes tipos de redes neurais artificiais, como redes neurais convolucionais, redes neurais recorrentes. Apresente exemplos de aplicações para cada tipo. (Valor 2.0)

Redes Neurais Convolucionais:

- As CNNs são usadas principalmente para processar dados estruturados em grade, como imagens.
- Elas usam convoluções para capturar features espaciais e padrões localizados.
- **Exemplo de aplicação:** Reconhecimento de imagens, detecção de objetos em vídeos, diagnósticos médicos.

Redes Neurais Recorrentes:

- As RNNs são usadas para processar dados sequenciais, como séries temporais.

- Elas têm conexões cíclicas que lhes permitem reter informações de estados anteriores.
- **Exemplo de aplicação:** Previsão de séries temporais, tradução automática, geração de texto.

Redes Neurais Feedforward:

- São a forma mais simples de redes neurais, em que as informações fluem em uma direção, da entrada para a saída.
- **Exemplo de aplicação:** Problemas de classificação e regressão onde a relação entre as entradas e saídas é direta.

Questão 4: Uma rede neural artificial com uma camada de 5 neurônios recebe um vetor de entrada de 3 elementos. A matriz de pesos entre a camada de entrada e a saída é dada pela matriz abaixo. A função de ativação dos neurônios da camada é a função sigmoide. O objetivo é calcular a saída da camada para um vetor de entrada dado por $[0.5, 0.6, 0.7]$.

$$\begin{bmatrix} 0.1 & 0.2 & 0.3 \\ 0.4 & 0.5 & 0.6 \\ 0.7 & 0.8 & 0.9 \\ 1.0 & 1.1 & 1.2 \\ 1.3 & 1.4 & 1.5 \end{bmatrix}$$

Para calcular a saída da camada, precisamos multiplicar o vetor de entrada pela matriz de pesos e, em seguida, aplicar a função de ativação sigmoide.

$$\text{entrada} = \begin{bmatrix} 0.5 \\ 0.6 \\ 0.7 \end{bmatrix}$$

$$\text{pesos} = \begin{bmatrix} 0.1 & 0.2 & 0.3 \\ 0.4 & 0.5 & 0.6 \\ 0.7 & 0.8 & 0.9 \\ 1.0 & 1.1 & 1.2 \\ 1.3 & 1.4 & 1.5 \end{bmatrix}$$

Primeiro, calculamos o produto ponto:

$$\mathbf{z} = \text{pesos} \cdot \text{entrada} = \begin{bmatrix} 0.1 \times 0.5 + 0.2 \times 0.6 + 0.3 \times 0.7 \\ 0.4 \times 0.5 + 0.5 \times 0.6 + 0.6 \times 0.7 \\ 0.7 \times 0.5 + 0.8 \times 0.6 + 0.9 \times 0.7 \\ 1.0 \times 0.5 + 1.1 \times 0.6 + 1.2 \times 0.7 \\ 1.3 \times 0.5 + 1.4 \times 0.6 + 1.5 \times 0.7 \end{bmatrix} = \begin{bmatrix} 0.38 \\ 0.92 \\ 1.46 \\ 2.00 \\ 2.54 \end{bmatrix}$$

Em seguida, aplicamos a função sigmoide:

$$\mathbf{a} = \sigma(\mathbf{z}) = \frac{1}{1 + e^{-\mathbf{z}}} = \begin{bmatrix} \frac{1}{1+e^{-0.38}} \\ \frac{1}{1+e^{-0.92}} \\ \frac{1}{1+e^{-1.46}} \\ \frac{1}{1+e^{-2.00}} \\ \frac{1}{1+e^{-2.54}} \end{bmatrix} \approx \begin{bmatrix} 0.593 \\ 0.715 \\ 0.811 \\ 0.881 \\ 0.927 \end{bmatrix}$$

Portanto, a saída da camada é aproximadamente $[0.593, 0.715, 0.811, 0.881, 0.927]$.

Questão 5: Explique o que é aprendizado profundo e como ele se diferencia do aprendizado de máquina tradicional. (Valor 1.0)

A aprendizagem profunda é um ramo da aprendizagem de máquina que se concentra no uso de redes neurais artificiais com muitas camadas, conhecidas como redes neurais profundas. Essas redes podem aprender representações de dados em vários níveis de abstração, o que lhes permite capturar padrões complexos nos dados.

Diferenças principais entre aprendizado profundo e aprendizado de máquina tradicional:

- **Complexidade:** Aprendizado de máquina tradicional frequentemente utiliza modelos mais simples, enquanto o aprendizado profundo usa redes neurais profundas com múltiplas camadas.
- **Requisitos de Dados:** Modelos de aprendizado profundo geralmente requerem grandes quantidades de dados para treinar eficientemente, enquanto métodos tradicionais podem funcionar bem com menos dados.
- **Poder Computacional:** A aprendizagem profunda requer maior poder computacional devido à complexidade das redes e ao volume de dados, muitas vezes utilizando GPUs para acelerar o treinamento.

Questão 6: Discuta o impacto do aprendizado profundo em diversas áreas, como visão computacional, processamento de linguagem natural e robótica. (Valor 1.0)

Visão Computacional:

- As redes neurais convolucionais estabeleceram o padrão em tarefas como reconhecimento de imagens, detecção de objetos e segmentação de imagens.
- **Exemplo:** Sistemas de diagnóstico médico que analisam imagens de raios-X para detectar doenças.

Processamento de Linguagem Natural:

- Modelos de redes neurais recorrentes, transformers e BERT têm melhorado significativamente tarefas de tradução automática, análise de sentimentos e geração de texto.
- **Exemplo:** Assistentes virtuais como Siri e Alexa, que entendem e respondem a comandos de voz.

Robótica:

- As redes neurais profundas são empregadas na robótica para controle de movimento, planejamento e percepção, permitindo que os robôs tenham maior autonomia e se adaptem a ambientes dinâmicos.
- **Exemplo:** Robôs autônomos que podem navegar em ambientes complexos e realizar tarefas específicas.